



N

Prezentacja końcowa

Generowanie i interpretacja reguł eksperskich dla klasyfikacji filmów **Netflix** z wykorzystaniem ML i LLM


Stas Kochevenko, Diana Hunchak

Cel projektu

Stworzenie systemu generującego interpretowalne reguły eksperckie na podstawie danych o filmach **Netflix** z wykorzystaniem uczenia maszynowego oraz modeli LLM.

System będzie klasyfikował filmy jako sukces lub porażkę, a następnie generował i interpretował reguły **IF-THEN**.


	director	cast	country	date_added	release_year	rating	duration	genres	language	description
k Forever After	Mike Mitchell	Mike Myers, Eddie Murphy, Cameron Diaz, Antonio Banderas, Walt Dohrn	United States of America	2010-05-16	2010	6.38		Comedy, Adventure, Fantasy, Animation, Family	en	A bored and domesticated Shrek pacts with deal-maker Rumpelstiltskin to
ction	Christopher Nolan	Leonardo DiCaprio, Joseph Gordon-Levitt, Ken Watanabe, Tom Hardy, Elliot Page	United Kingdom, United States of America	2010-07-15	2010	8.369		Action, Science Fiction, Adventure	en	Cobb, a skilled th
r Potter and the hly Hallows: 1	David Yates	Daniel Radcliffe, Emma Watson, Rupert Grint, Toby Jones, Helena Bonham Carter	United Kingdom, United States of America	2010-11-17	2010	7.744		Adventure, Fantasy	en	Harry, Ron and Hermione walk away from their li
led	Byron Howard, Nathan Greno	Mandy Moore, Zachary Levi, Donna Murphy, Ron Perlman, M.C. Gainey	United States of America	2010-11-24	2010	7.6		Animation, Family, Adventure	en	Feisty teenager Rapunzel, who has long and
to Train Your on	Chris Sanders, Dean DeBlois	Jay Baruchel, Gerard Butler, Craig Ferguson, America Ferrera, Jonah Hill	United States of America	2010-03-18	2010	7.8		Fantasy, Adventure, Animation	en	As the son of a Viking leader on the cusp of manhood, shy Hiccup
ter Island	Martin Scorsese	Leonardo DiCaprio, Mark Ruffalo, Ben Kingsley, Max von Sydow, Michelle Williams	United States of America	2010-02-14	2010	8.2		Drama, Thriller, Mystery	en	World War II soldier-turned-U.S. Marshal Teddy Daniels investigat
Grate Kid	Harald Zwart	Jaden Smith, Jackie Chan, Taraji P. Henson, Wenwen Han, Wang Zhenwei	China, Hong Kong, United States of America	2010-06-10	2010	6.5		Action, Adventure, Drama, Family	en	Twelve-year-old (Parker could have been the most popular kid in Detroit, but his
Man 2	Jon Favreau	Robert Downey Jr., Gwyneth Paltrow, Don Cheadle, Scarlett Johansson, Sam Rockwell	United States of America	2010-04-28	2010	6.8		Adventure, Action, Science Fiction	en	With the world not aware of his dual life as the armored superhero Iron Man, billionaire



Mechanizmy sztucznej inteligencji

Decision Tree

- Uczenie pod nadzorem na podstawie danych
- Klasyfikacja produkcji jako successful / unsuccessful
- Generowanie reguł IF-THEN




Symbolic rules

- Reprezentacja wiedzy w postaci reguł IF-THEN
- Interpretowalne decyzje systemu
- Wykorzystanie reguł w systemie ekspertowym




LLM

- Interpretacja wygenerowanych reguł
- Upraszczanie i analiza reguł
- Wykrywanie podobnych lub sprzecznych reguł



Architektura systemu



Preprocessing

- Usunięcie brakujących i niekompletnych danych
- Filtrowanie filmów o bardzo małej liczbie ocen (**vote_count < 50**)
- Usunięcie cech nieprzydatnych dla modelu (title, description, cast, director, show_id)
- Utworzenie zmiennej docelowej **is_success** na podstawie mediany **vote_average**
- Ekstrakcja głównego gatunku filmu (main_genre)

type	title	director	cast	country	date_added	release_year	rating	duration	genres	language	description	popularity	vote_count	vote_average
Movie	Shrek Forever After	Mike Mitchell	Mike Myers, Eddie Murphy, Cameron Diaz, Antoni...	United States of America	2010-05-16	2010	6.380	NaN	Comedy, Adventure, Fantasy, Animation, Family	en	A bored and domesticated Shrek pacts with deal...	203.893	7449	6.380
Movie	Inception	Christopher Nolan	Leonardo DiCaprio, Joseph Gordon-Levitt, Ken W...	United Kingdom, United States of America	2010-07-15	2010	8.369	NaN	Action, Science Fiction, Adventure	en	Cobb, a skilled thief who commits corporate es...	156.242	37119	8.369

Preprocessing

- Kodowanie zmiennych kategorycznych metodą One-Hot Encoding
- Usunięcie cech powodujących data leakage (**vote_average**)
- Podział danych na zbiór treningowy i testowy
- Standaryzacja i przygotowanie danych do uczenia modelu Decision Tree

Próg sukcesu (mediana ocen): 6.40

Gotowy zbiór danych do budowy modelu (Decision Tree Classifier):

	country	release_year	language	popularity	vote_count	budget	revenue	is_success	main_genre
0	United States of America	2010	en	203.893	7449	165000000	752600867	0	Comedy
1	United Kingdom, United States of America	2010	en	156.242	37119	160000000	839030630	1	Action
2	United Kingdom, United States of America	2010	en	121.191	19327	250000000	954305868	1	Adventure
3	United States of America	2010	en	111.762	11638	260000000	592461732	1	Animation
4	United States of America	2010	en	110.044	13259	165000000	494879471	1	Fantasy

Rozmiar zbioru treningowego: (9748, 1372)

Rozmiar zbioru testowego: (2437, 1372)

Trenowanie Decision Tree

- Model osiągnął **accuracy** na poziomie około **68%**, co oznacza, że poprawnie klasyfikował około 2/3 filmów ze zbioru testowego
- Najlepsze wyniki uzyskano dla klasy **successful (1)**, dla której **recall** osiągnął wartość **0.73**
- Model zachowuje względną równowagę pomiędzy obiema klasami i nie wykazuje silnego biasu w kierunku jednej kategorii.


Accuracy modelu: 0.6767

Classification Report:

	precision	recall	f1-score	support
0	0.67	0.61	0.64	1144
1	0.68	0.73	0.71	1293
accuracy			0.68	2437
macro avg	0.68	0.67	0.67	2437
weighted avg	0.68	0.68	0.68	2437

Wpływ głębokości drzewa na model

- Większa głębokość zwiększa accuracy modelu
- Największy wzrost skuteczności wystąpił dla depth 2–4
- Większe drzewa generują więcej reguł IF-THEN, co obniża interpretowalność modelu
- Wybrano kompromis pomiędzy accuracy a czytelnością reguł




Liczba reguł a głębokość drzewa


- Liczba reguł rośnie bardzo szybko wraz z głębokością drzewa
- Dla większych wartości depth model generuje ponad 100 reguł



Wizualizacja drzewa decyzyjnego




Statystyki cech



Importance określa, jak duży wpływ dana cecha miała na podejmowanie decyzji przez model

Confusion matrix

- Macierz błędów pokazuje liczbę poprawnych i błędnych klasyfikacji modelu
- Model poprawnie sklasyfikował większość filmów successful
- Skuteczność dla klasy successful była wyższa niż dla unsuccessful
- Model zachował względną równowagę pomiędzy obiema klasami
- Nie zaobserwowano silnego biasu w kierunku jednej kategorii



Ekstrakcja reguł IF-THEN

```
|--- main_genre_Horror <= 0.500
| |--- popularity <= 13.291
| | |--- main_genre_Documentary <= 0.500
| | | |--- language_en <= 0.500
| | | | |--- main_genre_Comedy <= 0.500
| | | | | |--- weights: [523.000, 1125.000] class: 1
| | | | |--- main_genre_Comedy > 0.500
| | | | | |--- weights: [366.000, 223.000] class: 0
| | | |--- language_en > 0.500
| | | | |--- main_genre_Music <= 0.500
| | | | | |--- weights: [1721.000, 935.000] class: 0
| | | | |--- main_genre_Music > 0.500
| | | | | |--- weights: [8.000, 56.000] class: 1
| | |--- main_genre_Documentary > 0.500
| | |--- vote_count <= 80.500
| | | |--- release_year <= 2014.500
| | | | |--- weights: [2.000, 31.000]
```

Rule 1:

IF (main_genre_Horror <= 0.500) AND (popularity <= 13.291) AND (main_genre_Documentary <= 0.500)
AND (language_en <= 0.500) AND (main_genre_Comedy <= 0.500) THEN class = 1

Rule 2:

IF (main_genre_Horror <= 0.500) AND (popularity <= 13.291) AND (main_genre_Documentary <= 0.500)
AND (language_en <= 0.500) AND (main_genre_Comedy > 0.500) THEN class = 0

Rule 3:


IF (main_genre_Horror <= 0.500) AND (popularity <= 13.291) AND (main_genre_Documentary <= 0.500)
AND (language_en > 0.500) AND (main_genre_Music <= 0.500) THEN class = 0

Rule 4:

IF (main_genre_Horror <= 0.500) AND (popularity <= 13.291) AND (main_genre_Documentary <= 0.500)
AND (language_en > 0.500) AND (main_genre_Music > 0.500) THEN class = 1

Ekstrakcja reguł IF-THEN

- **Popularity** była najważniejszą cechą wpływającą na klasyfikację filmu
- Filmy z gatunku Horror częściej były klasyfikowane jako **unsuccessful**
- Filmy Documentary i Animation częściej osiągały klasę **successful**
- **Vote_count** pełnił rolę dodatkowego wskaźnika wiarygodności sukcesu filmu
- Cechy release_year, revenue oraz language miały mniejszy wpływ na decyzje modelu
- Wygenerowane reguły mają interpretowalny charakter i mogą pełnić rolę bazy wiedzy systemu ekspertowego



Analiza jakości reguł IF-THEN


	rule	predicted_class	support	confidence	conditions_count
29	IF main_genre_Horror > 0.500 AND popularity > ...	1	23	1.000	5
19	IF main_genre_Horror > 0.500 AND popularity <=...	0	220	0.968	5
6	IF main_genre_Horror <= 0.500 AND popularity <...	1	217	0.954	5
9	IF main_genre_Horror <= 0.500 AND popularity >...	1	130	0.954	5
13	IF main_genre_Horror <= 0.500 AND popularity >...	1	212	0.953	5
4	IF main_genre_Horror <= 0.500 AND popularity <...	1	33	0.939	5
25	IF main_genre_Horror > 0.500 AND popularity > ...	0	23	0.913	4
22	IF main_genre_Horror > 0.500 AND popularity <=...	0	88	0.909	5
15	IF main_genre_Horror <= 0.500 AND popularity >...	1	57	0.895	5
20	IF main_genre_Horror > 0.500 AND popularity <=...	0	193	0.891	5

Confidence określa, jaki procent przykładów spełniających daną regułę został poprawnie sklasyfikowany przez model. **Do dalszej analizy wykorzystano wyłącznie reguły o confidence ≥ 0.75 .**

Support oznacza liczbę przykładów treningowych objętych daną regułą IF-THEN.

Analiza jakości reguł IF-THEN

- Niektóre reguły osiągały bardzo wysoką wartość confidence (nawet 1.0)
- Część reguł obejmowała niewielką liczbę przykładów treningowych
- Wiele reguł zachowywało jednocześnie wysoki support oraz wysoki confidence
- Uzyskane reguły można uznać za stosunkowo stabilne i wiarygodne



Analiza reguł przez LLM

01

Expert Rules

Tłumaczenie technicznych IF-THEN na język naturalny.

02

Knowledge Patterns

Grupowanie podobnych reguł w szersze wzorce wiedzy.

03

Redundancja

Wskazanie zbędnych warunków i możliwych scaleń.

04

Konflikty i wyjątki

Opis anomalii oraz granic między decyzjami modelu.

05

Czynniki sukcesu

Wyjaśnienie, które cechy najmocniej wspierają klasę 1.

FRAGMENT PROMPTU

IMPORTANT: This is an ANALYSIS ONLY step.
Do NOT modify, merge, or remove any rules.

Your tasks:

1. Rewrite each rule into a clear expert rule.
2. Group similar rules into knowledge patterns.
3. Identify redundant rules and conditions.
4. Identify conflicts and exceptions.
5. Explain movie success factors.

Return the result in Polish.

Na tym etapie Gemini tylko analizuje 19 reguł. Modyfikacje są wykonywane w kolejnych, osobnych krokach.

Analiza reguł przez LLM

1. Czytelne reguły eksperckie:

Reguła 1: JEŚLI główny gatunek to Horror (ponad 50% udziału) ORAZ popularność jest wysoka (ponad 73.279), ORAZ liczba głosów jest wysoka (ponad 878), WÓWCZAS film jest sukcesem. *Przewidywana klasa: sukces*

Reguła 2: JEŚLI główny gatunek to Horror (ponad 50% udziału) ORAZ popularność jest niska (poniżej lub równo 12.900), ORAZ język to angielski (ponad 50% udziału), ORAZ rok wydania jest stary (poniżej lub równo 2016.5), WÓWCZAS film jest niepowodzeniem. *Przewidywana klasa: niepowodzenie*

Reguła 3: JEŚLI główny gatunek to nie Horror (poniżej lub równo 50% udziału) ORAZ popularność jest niska (poniżej lub równo 13.291), ORAZ główny gatunek to Dokumentaryczny (ponad 50% udziału), ORAZ liczba głosów jest umiarkowana (ponad 80.5), ORAZ budżet jest niski (poniżej lub równo 40851.5), WÓWCZAS film jest sukcesem. *Przewidywana klasa: sukces*

2. Grupowanie podobnych reguł (wzorce wiedzy):

- **Wzorzec 1: Filmy gatunku Horror z wysoką popularnością i liczbą głosów są udane.**
 - Reguła 1, Reguła 16
 - *Komentarz:* Te reguły podkreślają, że filmy gatunku Horror, jeśli osiągną znaczącą popularność i zaangażowanie widzów (mierzone liczbą głosów), mają dużą szansę na sukces.
- **Wzorzec 2: Filmy gatunku Horror z niską popularnością i angielskim językiem, ale starsze lub z niskimi przychodami, są nieudane.**
 - Reguła 2, Reguła 8, Reguła 10, Reguła 17
 - *Komentarz:* Wydaje się, że angielskojęzyczne filmy grozy, które nie zdobywają szerokiej popularności, mają wyższe szanse na porażkę, zwłaszcza jeśli są starsze lub ich przychody są ograniczone.

Analiza reguł przez LLM

3. Zidentyfikowane reguły i warunki redundantne:

Redundancja warunków w ramach jednej reguły:

- **Reguła 1:** Warunki `popularity > 24.176`, `popularity > 48.583`, `popularity > 73.279` są częściowo redundantne. Jeśli `popularity > 73.279` jest spełnione, to pozostałe również są spełnione. `popularity > 73.279` implikuje `popularity > 48.583`, a to z kolei implikuje `popularity > 24.176`. Najbardziej restrykcyjny warunek (`popularity > 73.279`) jest wystarczający.
- **Reguła 16:** Analogicznie do Reguły 1, warunki `popularity > 24.176` i `popularity > 48.583` są częściowo redundantne w stosunku do `popularity > 48.583` (które już jest węższe niż `popularity > 24.176`) i `popularity <= 73.279`. W tym przypadku, `popularity > 48.583` i `popularity <= 73.279` można by zapisać jako `48.583 < popularity <= 73.279`.

4. Konflikty i wyjątki:

Na podstawie podanych reguł nie występują *bezpośrednie konflikty* w sensie, że dwie reguły z dokładnie tymi samymi warunkami prowadzą do różnych klas. Model decyzji oparty na drzewie decyzyjnym zazwyczaj zapewnia, że każdy zestaw danych zostanie przypisany do jednej konkretnej ścieżki decyzyjnej.

Jednakże, można zauważyć **potencjalne anomalie lub złożoność**, szczególnie w kontekście gatunku Horror:

- **Horror - wysoka popularność:**
 - Reguła 1 i Reguła 16 przewidują sukces dla horrorów o wysokiej popularności i dużej liczbie głosów.
 - Reguła 7 przewiduje niepowodzenie dla horrorów o wysokiej popularności, ale niskiej liczbie głosów i wysokim budżecie.
 - Reguła 19 przewiduje niepowodzenie dla horrorów o wysokiej popularności, niskiej liczbie głosów, bardzo niskim budżecie i przychodach.
 - *Anomalia/Złożoność:* Wydaje się, że wysoka popularność w horrorach jest dobrym wskaźnikiem sukcesu tylko wtedy, gdy towarzyszy jej duża liczba głosów (zaangażowanie). Jeśli popularność jest wysoka, ale liczba głosów jest niska, film może zostać uznany za niepowodzenie, nawet jeśli budżet jest wysoki (Reguła 7) lub niski (Reguła 19). To sugeruje, że wysoka popularność bez pokrycia w zaangażowaniu widzów może być problematyczna.

5. Co system uważa za czynnik sukcesu filmu:

Na podstawie analizy reguł można stwierdzić, że system uważa następujące czynniki za potencjalne **czynniki sukcesu** filmu:

- **Wysoka popularność:** Jest to często powtarzający się warunek w regułach prowadzących do sukcesu (np. Reguła 1, 4, 5, 9, 11, 15, 16).
- **Duża liczba głosów (zaangażowanie widzów):** Jest to kluczowy wskaźnik, szczególnie w przypadku horrorów i filmów innych gatunków, gdzie wysoka liczba głosów często koreluje z sukcesem (np. Reguła 1, 4, 11, 16).
- **Określone gatunki:**
 - **Horror:** Gdy towarzyszy mu wysoka popularność i liczba głosów (Reguła 1, 16).
 - **Dokumentaryczny:** Może odnosić sukces nawet przy niższej popularności, pod warunkiem umiarkowanej liczby głosów (Reguła 3, 14).
 - **Animacja:** Sukces jest przewidywany przy umiarkowanej/wysokiej popularności i odpowiednim budżecie (Reguła 5, 9, 15).
 - **Dramat:** W połączeniu z wysoką popularnością i liczbą głosów (Reguła 11).
 - **Muzyka (lub inne, nie horror/dokument):** Może osiągnąć sukces nawet przy niskiej popularności, jeśli jest w języku angielskim (Reguła 12).

LLM pracuje na regułach zapisanych jako JSON

19 → 16

reguł po przetworzeniu



```
{  
  "rule": "IF popularity > 73.279 ...",  
  "predicted_class": 1,  
  "support": 23,  
  "confidence": 1.0  
}
```

Ograniczenia w promptach

- zachowaj ten sam schemat JSON
- nie łącz reguł przy niepewności
- minimum 80% pierwotnej liczby reguł
- JSON ma zaczynać się od [i kończyć]
- fallback do poprzedniej wersji przy błędzie

Redundacja reguł i warunków

19 → 16

reguł po przetworzeniu

	PRZED		PO
Warunek wewnątrz reguły	<pre>popularity > 24.176 AND popularity > 48.583 AND popularity > 73.279</pre>	→	<pre>popularity > 73.279</pre>
Scalenie Reguły 2 + 10	<pre>te same warunki, release_year ≤ 2016.5 lub release_year > 2016.5</pre>	→	<pre>usunięto podział po release_year</pre>
Scalenie Reguły 6 + 18	<pre>dokument, vote_count ≤ 80.5, release_year ≤ 2014.5 lub release_year > 2014.5</pre>	→	<pre>jedna reguła bez warunku release_year</pre>

Gemini zwraca komentarze do zmian oraz oczyszczoną tablicę JSON; struktura jest sprawdzana osobno

Identyfikacja konfliktów i wyjątków

Drzewo decyzyjne nie tworzy bezpośrednich sprzeczności. LLM oznacza głównie wyjątki, anomalie i granice decyzji.

15 / 16

reguła z polem conflict_note

HORROR	Sukces popularity > 73.279 vote_count > 878	↔	Wyjątek: porażka popularity > 24.176 vote_count ≤ 878
DOKUMENT	Sukces przy niskim budżecie popularity ≤ 13.291 budget ≤ 40 851.5	↔	Sukces także przy wyższym budżecie popularity ≤ 13.291 budget > 40 851.5
ANIMACJA	Budżet ≤ 35.5 mln wystarcza popularity > 17.012	↔	Budżet > 35.5 mln wymagane popularity > 32.837

Pole conflict_note zachowuje wyjaśnienie razem z regułą w finalnym JSON

Walidacja JSON i tłumaczenie na Expert Rules

JSON OK

16 reguł, wszystkie pola poprawne.

Sprawdzane elementy:

- ✓ pola rule, predicted_class, support, confidence
- ✓ predicted_class ma wartość 0 albo 1
- ✓ support i confidence są liczbami
- ✓ odpowiedź daje się ponownie zserializować
- ✓ przy błędzie zachowywany jest poprzedni JSON

Reguła techniczna

```
IF main_genre_Horror > 0.500  
AND popularity > 73.279  
AND vote_count > 878.000  
THEN class = 1
```

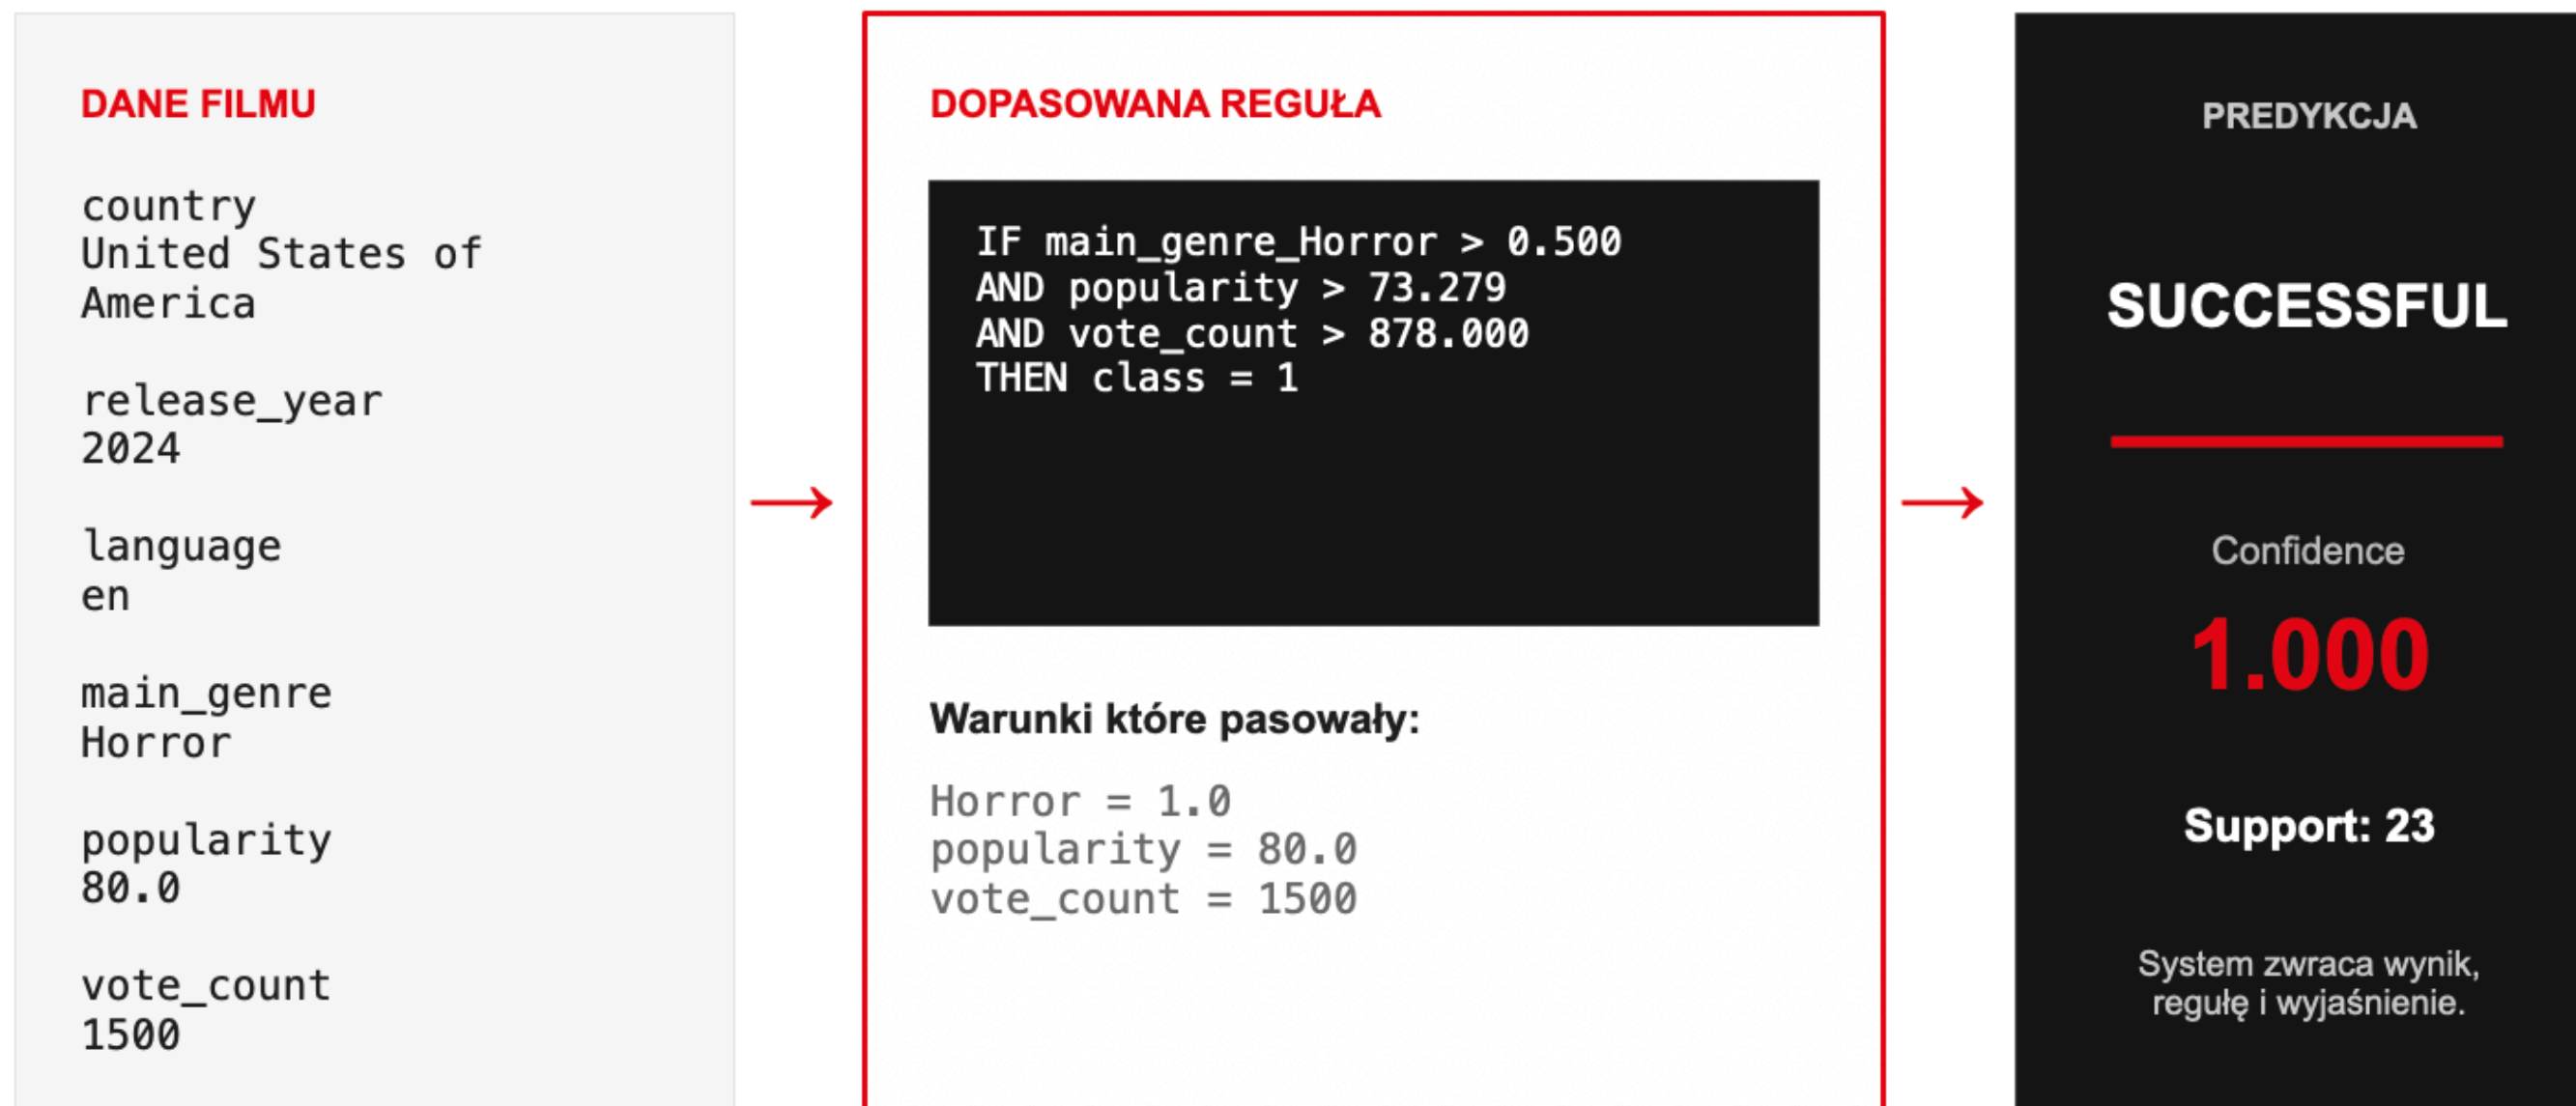
↓ **Gemini: tłumaczenie tekstowe, bez JSON**

JEŚLI film jest horrorem, jego popularność przekracza 73.279, a liczba głosów jest większa niż 878, WTEDY film zostaje sklasyfikowany jako sukces.

Support: 23 | Confidence: 1.000

Najpierw kontrolowana jest struktura danych, a dopiero potem generowane jest wyjaśnienie dla człowieka

Przykładowe użycie demonstracji



Live Demo działa bez ponownego wywoływania LLM: predykcja korzysta z zapisanych reguł JSON

Wnioski końcowe

01

Co identyfikuje system ekspertowy?

Kluczowe czynniki klasyfikacji to popularność, liczba głosów, główny gatunek, język, budżet oraz rok wydania.

02

Co w projekcie oznacza successful?

Klasa successful oznacza `vote_average` co najmniej równy medianie ocen w zbiorze. Nie jest to bezpośrednia miara sukcesu finansowego ani biznesowego Netflix.

03

Jaka jest rola LLM?

LLM nie zastępuje Decision Tree. Interpretuje, upraszcza, grupuje i porządkuje reguły IF-THEN, tworząc bardziej zrozumiałą bazę wiedzy.

Decision Tree podejmuje decyzję. LLM pomaga człowiekowi ją zrozumieć.

Finalny rezultat: klasyfikator ML + uporządkowana i wyjaśnialna baza reguł eksperckich.

The background is a solid red color. It is decorated with three sets of white, wavy, concentric lines. One set is on the left side, another is in the top right corner, and a third is in the bottom right corner. These lines create a sense of movement and depth.

Dziękujemy za uwagę!